Mestrado em Matemática Financeira

Study of Implied Volatility Surface with Machine Learning Techniques

Departamento de Finanças

Departamento de Matemática

Sérgio Sobral

Orientadores:

PhD Diana Elisabeta Aldea Mendes, Associate Professor, ISCTE-IUL

Agenda

Introdução	**02**
Tratamento de Dados	**09**
Metodologia e Resultados	**21**
Conclusão e Recomendações	**24**

INTRODUÇÃO
4-8

TRATAMENTO DE DADOS
10-12

METODOLOGIA E RESULTADOS
14-22

CONCLUSÃO E RECOMENDAÇÕES
24-25

Enquadramento



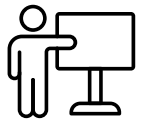
Importância nos Mercados

As opções são **amplamente utilizadas**, por instituições e investidores, para estratégias de *hedging*, gestão de risco e perfis de *payoff* assimétricos.



Crescimento Exponencial

O volume de opções sobre ações negociadas na CBOE cresceu de 1.12 milhões de contratos em 1973 para mais de **6.5 mil milhões em 2024**.



Volatilidade Implícita

A volatilidade implícita (IV) assume um papel central, na medida em que reflete as **expectativas do mercado sobre a incerteza futura**.

Evolução Histórica da Modelização da IVS

1973 **Modelo Black–Scholes–Merton**

Introduz o primeiro modelo fechado para *pricing* de opções, assumindo volatilidade constante e originando o conceito de IV por inversão.

1987 ***Crash* dos Mercados de Opções**

O colapso revelou *smiles* e *skews* pronunciados, expondo as limitações da volatilidade constante e revelando padrões sistemáticos na *Implied Volatility Surface* (IVS).

Evolução Histórica da Modelização da IVS

1990s — **Modelos Clássicos**

Diversos modelos empíricos e estocásticos procuraram capturar a estrutura da IVS, mas geravam formas instáveis ou insuficientes face à complexidade real da superfície.

2002 — **Cont & Da Fonseca**

Análise via *Principal Component Analysis* (PCA) mostra que nível, inclinação e curvatura explicam a maior parte da variação da IVS, revelando uma superfície previsível e estruturada.

Evolução Histórica da Modelização da IVS

2010s–2020s

Abordagens *Data-Driven*

Modelos *Machine Learning* (ML) e Híbridos capturam padrões estruturais e variações da IVS com maior flexibilidade, superando métodos clássicos em precisão e estabilidade.

Motivação

1. **Métodos de *Machine Learning***

   Avaliar se **métodos de ML superam modelos clássicos** na modelização da IVS.

2. **Abordagem Híbrida**

   Avaliar se a **maior versatilidade dos modelos híbridos** se traduz em resultados comparáveis.

3. ***Framework* Modular**

   Desenvolver para toda a análise de uma ***pipeline* consistente e reprodutível.**

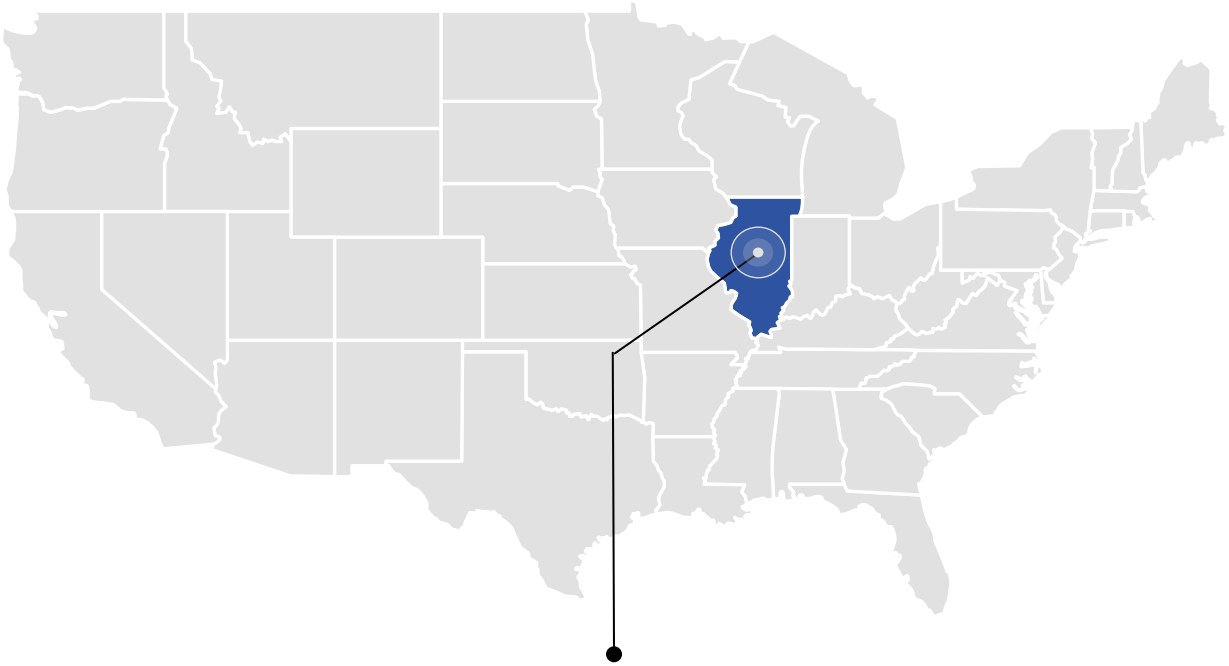
INTRODUÇÃO
4-8

TRATAMENTO DE DADOS
10-12

METODOLOGIA E RESULTADOS
14-22

CONCLUSÃO E RECOMENDAÇÕES
24-25

Dados Utilizados



***Chicago Board Options Exchange* (CBOE)**

SPX *Options*

Opções Europeias
cash-settled com elevada liquidez

Snapshot Intradiário
15h45

Período de análise

- **2009-2019**
- **Dados diários**, cobrindo múltiplos regimes de volatilidade e taxas de juro

Dimensão da amostra

Aproximadamente **15.1 milhões de observações** de opções antes de qualquer filtragem

Variáveis de modelização

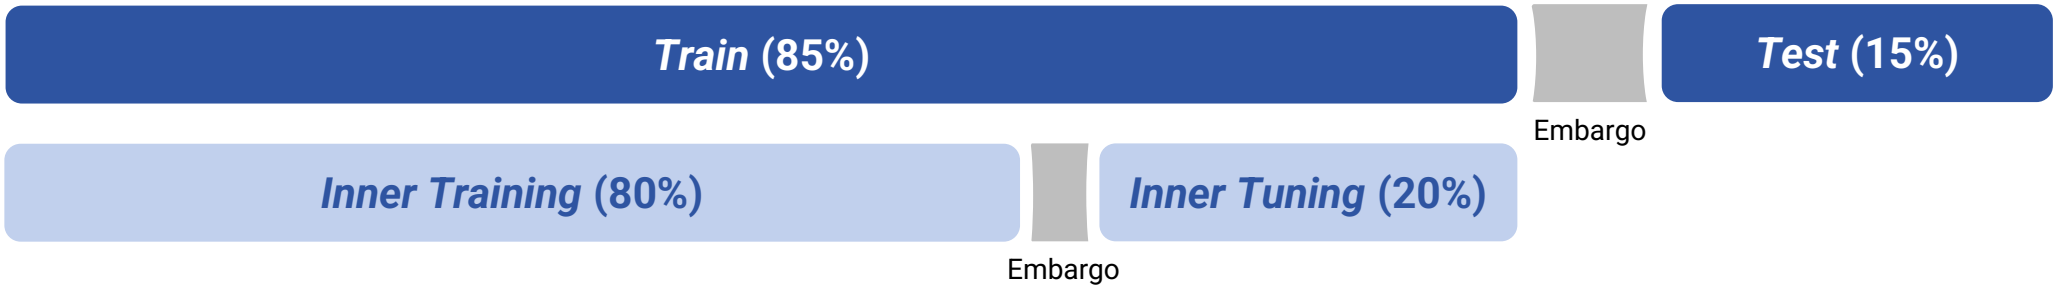
VARIÁVEIS EXPLICATIVAS CONSTRUÍDAS
Log-moneyness
Tempo até à maturidade
Indicador binário de tipo de opção
Taxa de juro livre de risco

Base de Modelização

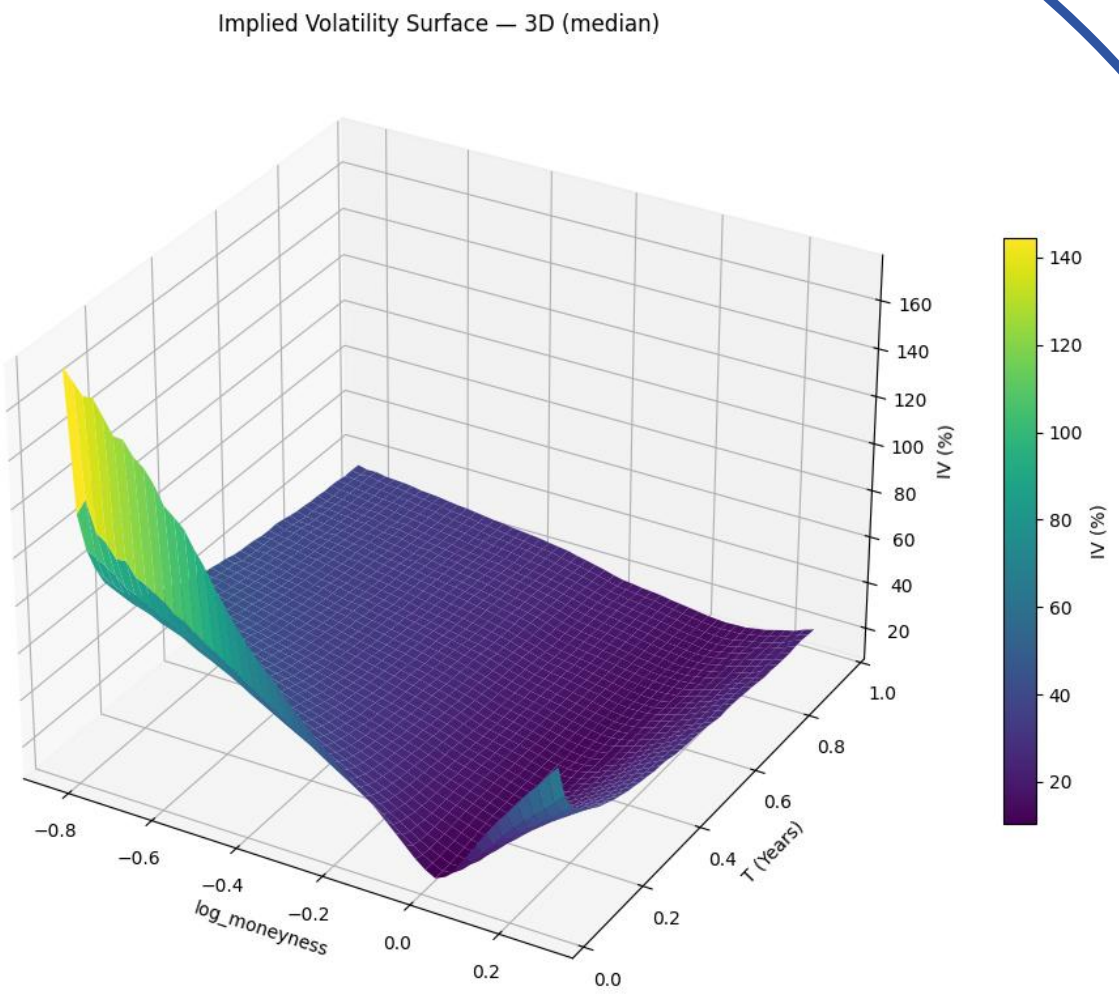
Etapas de Construção da Base de Modelização



Separação Treino - Teste



IVS Teórica



1. Faixa Realista de Volatilidades
2. Dependência Forte da *Moneyness*
3. *Smile* Assimétrico e *Skew* Negativo
4. Efeito da Maturidade
5. Variância Total Monótona

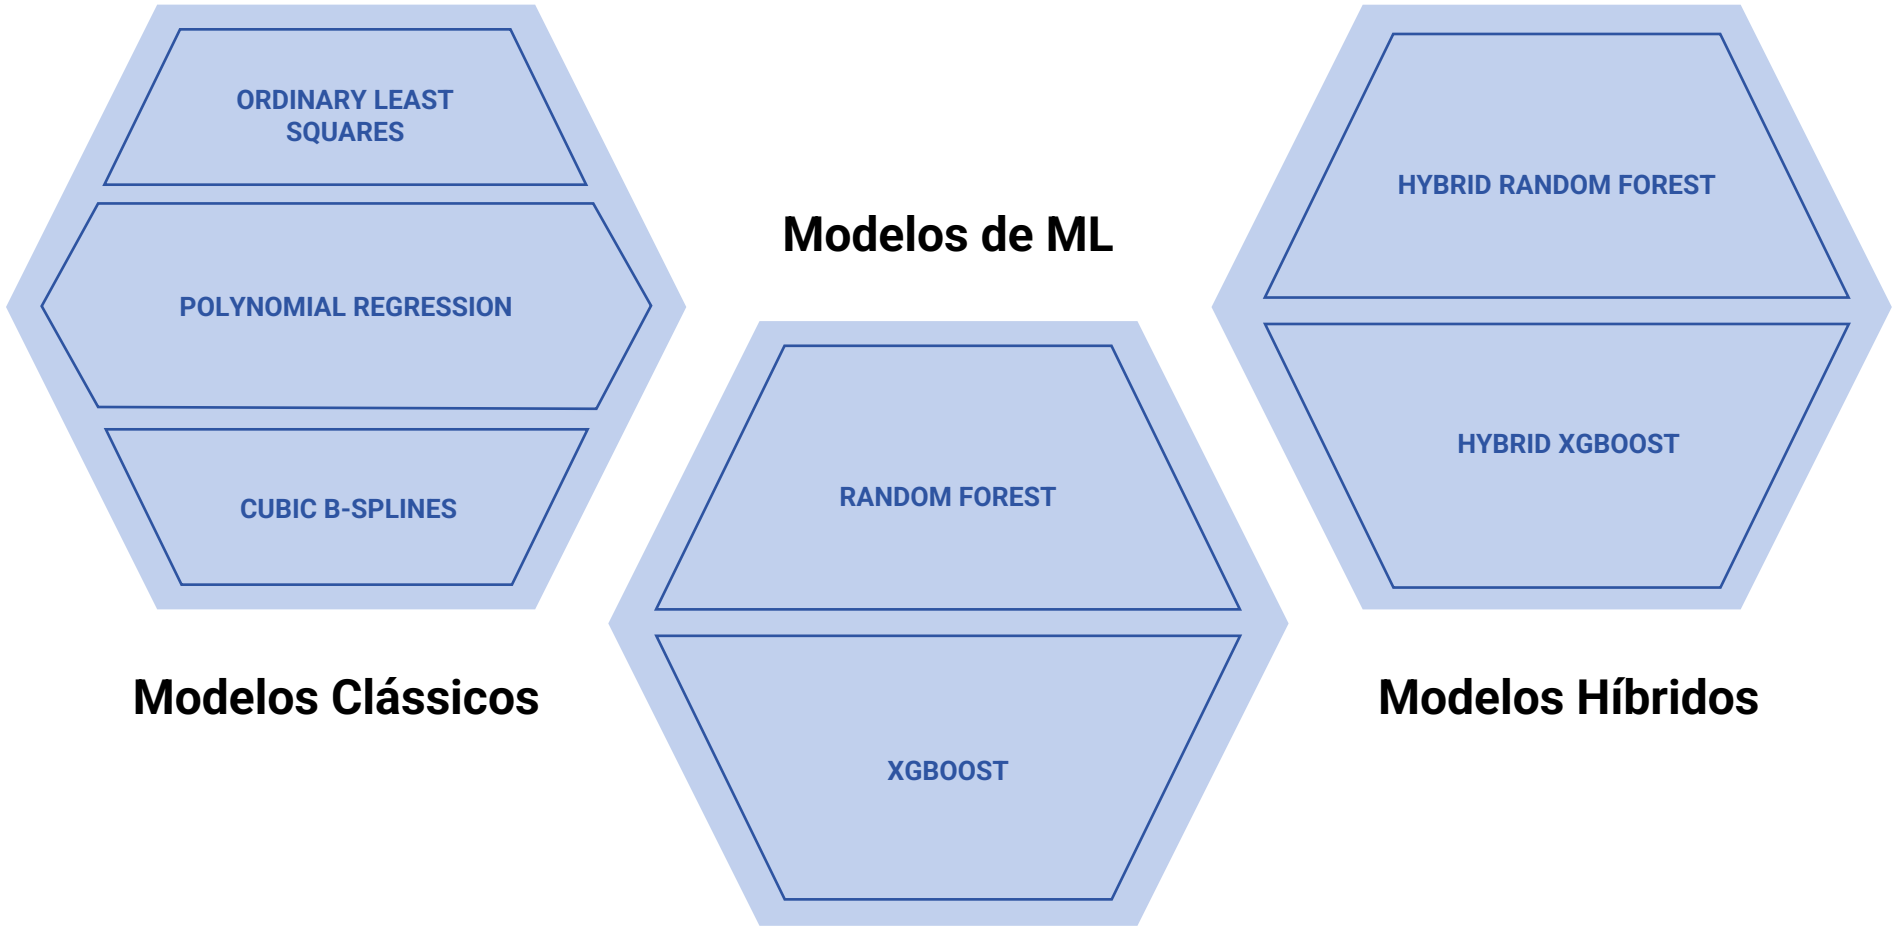
INTRODUÇÃO
4-8

TRATAMENTO DE DADOS
10-12

METODOLOGIA E RESULTADOS
14-22

CONCLUSÃO E RECOMENDAÇÕES
24-25

Metodologias aplicadas



Ordinary Least Squares (OLS)

Formulação

$$IV_i^{OLS} = \beta_0 + \beta_1 m_i + \beta_2 T_i + \varepsilon_i$$

- m_i - *Log-moneyness*
- T_i - Tempo até à maturidade
- ε_i - ruído branco (média zero, variância constante)

Estimativa OLS

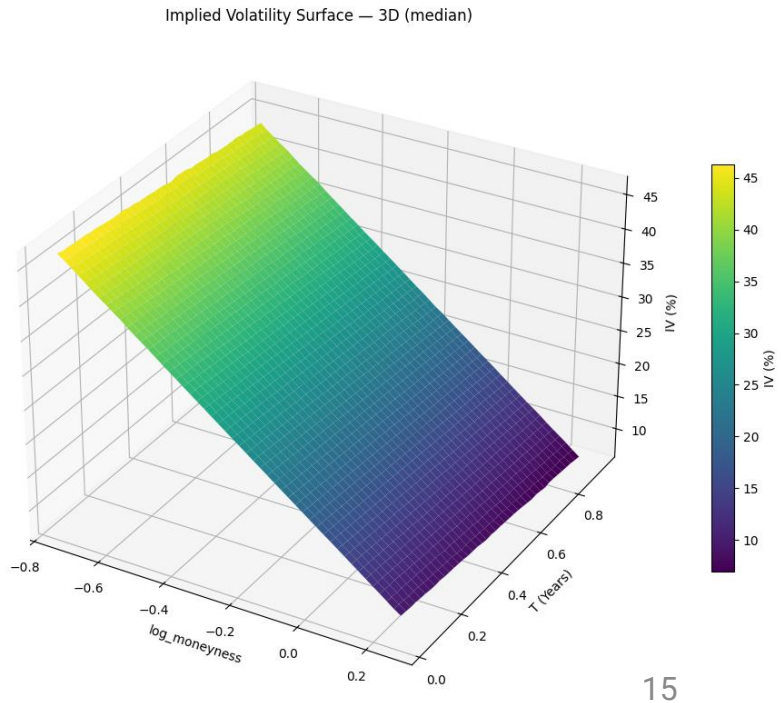
$$\hat{\beta} = \arg\min_{\beta} \sum_i \left(IV_i - \mathrm{x}_i^{\mathsf{T}} \beta\right)^2$$

Resultados

O modelo apresenta um R^2 muito reduzido, na ordem dos 40%, e um RMSE elevado, evidenciando uma capacidade explicativa muito limitada. Os resíduos apresentam **claros sinais de estrutura não explicada pelo modelo**.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0981	0,0655	0,0507	1,498	1,292	38,36	0,0000
Teste	0,0892	0,0571	0,0392	1,562	1,456	41,39	-0,0140

A rigidez da relação linear impede o OLS de capturar o *smile* e o *skew*, tornando-o **essencialmente um *baseline***, útil apenas como referência para avaliar melhorias nos modelos mais flexíveis.



Polynomial Regression

Formulação

$$IV_i^{Poly} = \beta_0 + \sum_{a+b \le d} \beta_{ab}\, m_i^a\, T_i^b + \varepsilon_i$$

- m_i - *log-moneyness*
- T_i - Tempo até à maturidade
- ε_i - ruído branco

Regularização *Ridge* (L2)

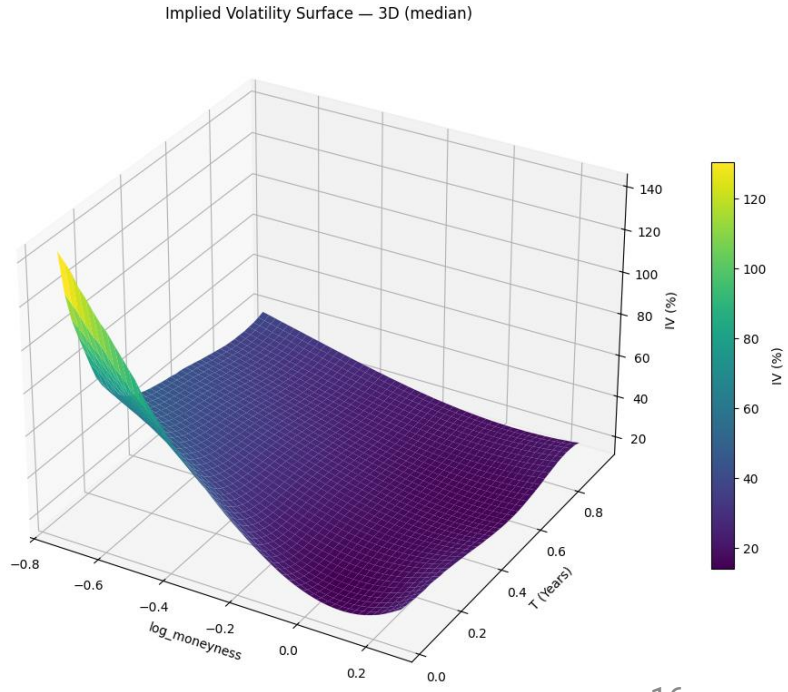
$$\hat{\beta} = \arg\min_{\beta} \left[\sum_i (IV_i - \mathrm{x}_i^{\mathsf{T}} \beta)^2 + \alpha \sum_j \beta_j^2 \right]$$

Resultados

O modelo polinomial apresenta R^2 e RMSE substancialmente melhores comparativamente ao modelo OLS, embora ainda com desempenho muito limitado, **incapaz de explicar grande parte da variância da superfície**.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0632	0,0445	0,0343	1,420	1,296	74,42	0,0000
Teste	0,0594	0,0420	0,0326	1,414	1,289	74,01	-0,0122

A superfície ajustada aproxima-se da IVS teórica e os resíduos tornam-se mais estreitos e simétricos, mas o modelo continua a subestimar regiões de maturidades curtas e *moneyness* extremos, revelando **limitações nas zonas mais exigentes da superfície**.



Cubic B-Splines

Base Unidimensional (*B-Splines* Cúbicas)

$$\mathrm{B}_m(m_i) = (B_{m,1}(m_i), \dots, B_{m,p}(m_i))$$

$$\mathrm{B}_T(T_i) = (B_{T,1}(T_i), \dots, B_{T,q}(T_i))$$

- Padronização m_i e T_i (z-score)
- *Knots* por quantis
- Extrapolação linear nas extremidades

Tensor-Product Spline

$$IV_i^{Spline} = \sum_{r=1}^{p}\sum_{s=1}^{q} \theta_{rs} B_{m,r}(m_i) B_{T,s}(T_i) + \varepsilon_i$$

Regularização *Ridge* (L2)

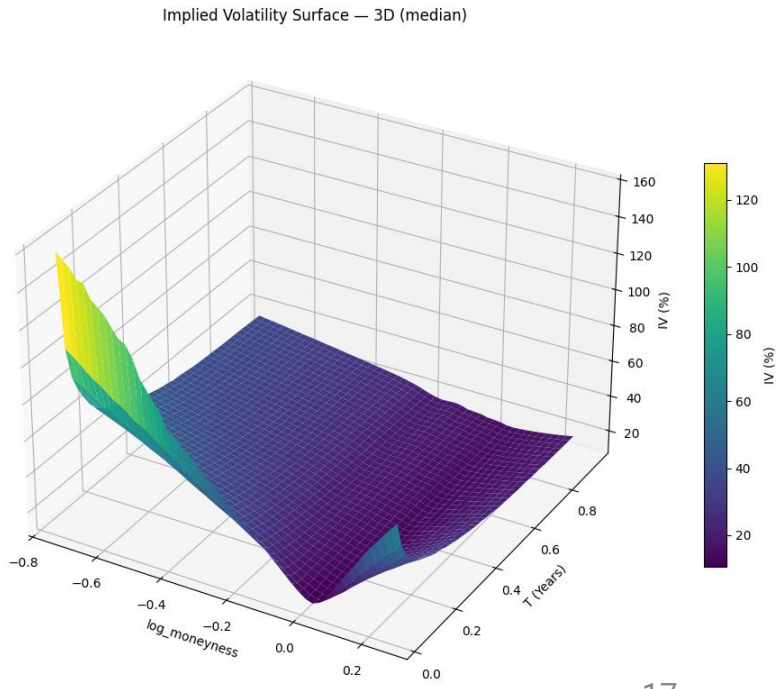
$$\hat{\theta} = \arg\min_{\theta} \left[\sum_i (IV_i - \mathrm{z}_i^{\mathsf{T}}\theta)^2 + \alpha \sum_j \theta_j^2\right],$$

Resultados

O modelo de *splines* atinge um R^2 de 86,3% e um RMSE de 0,043, representando cerca de 35% da volatilidade da amostra e um **ganho claro face ao modelo polinomial**.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0459	0,0327	0,0250	1,402	1,310	86,51	0,0000
Teste	0,0431	0,0324	0,0249	1,331	1,298	86,33	-0,0103

A superfície ajustada torna-se mais suave e próxima da forma teórica, com resíduos mais concentrados e quase sem padrões estruturais, revelando um modelo já bastante robusto apesar de **pequenas falhas nos extremos da superfície**.



Random Forest

Formulação

$$IV_i^{RF} = \frac{1}{B}\sum_{b=1}^{B} f_b(x_i)$$

- Ensemble de *B* árvores (média das previsões individuais)
- $x_i = (m_i, T_i, option_type)$
- Balanced sampling no espaço (m, T)

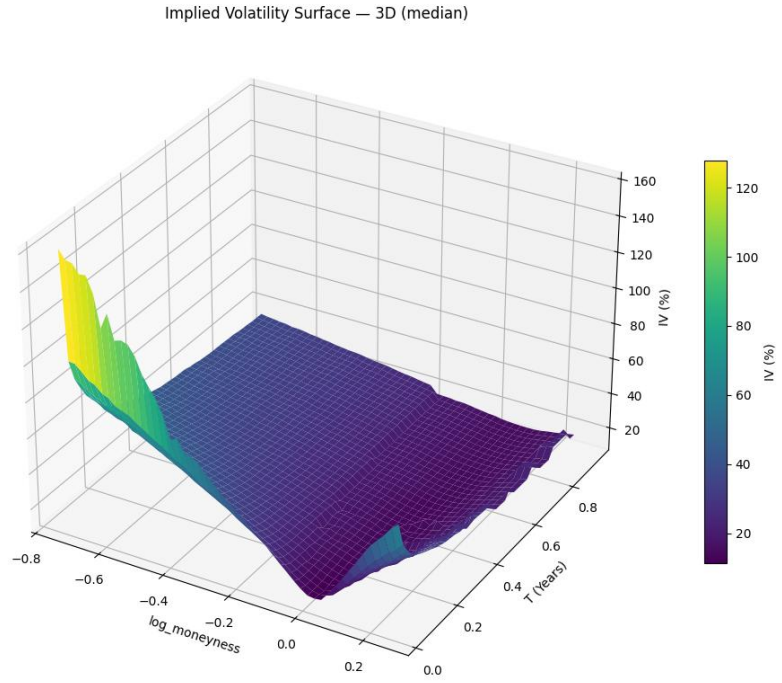
HIPERPARÂMETROS
n_estimators
max_depth
min_samples_leaf
min_samples_split
max_features
max_samples

Resultados

O modelo atinge um R^2 de 89,2% e um RMSE de 0,0384, representando cerca de 31% da volatilidade média, o que confirma um **ganho expressivo de capacidade explicativa**.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0421	0,0288	0,0214	1,462	1,346	88,65	0,0000
Teste	0,0384	0,0275	0,0193	1,395	1,422	89,16	-0,0114

Observamos uma precisão global muito satisfatória, com o diagnóstico gráfico a mostrar um ajuste limpo, sem padrões estruturais relevantes, evidenciando que **o *Random Forest* captura a maioria das não-linearidades da superfície**.



XGBoost

Formulação

$$\mathrm{IV}_i^{XGB} = \sum_{m=1}^{M} \eta\, f_m(x_i)$$

- *Boosting* (árvores sequenciais corrigem resíduos)
- $x_i = (m_i, T_i, optio_type)$
- *Balanced sampling* no espaço (m, T)
- *Loss* regularizado e penalização de complexidade

HIPERPARÂMETROS
n_estimators
learning_rate
max_depth
min_child_weight
gamma
subsample
colsample_bytree
reg_lambda
reg_alpha

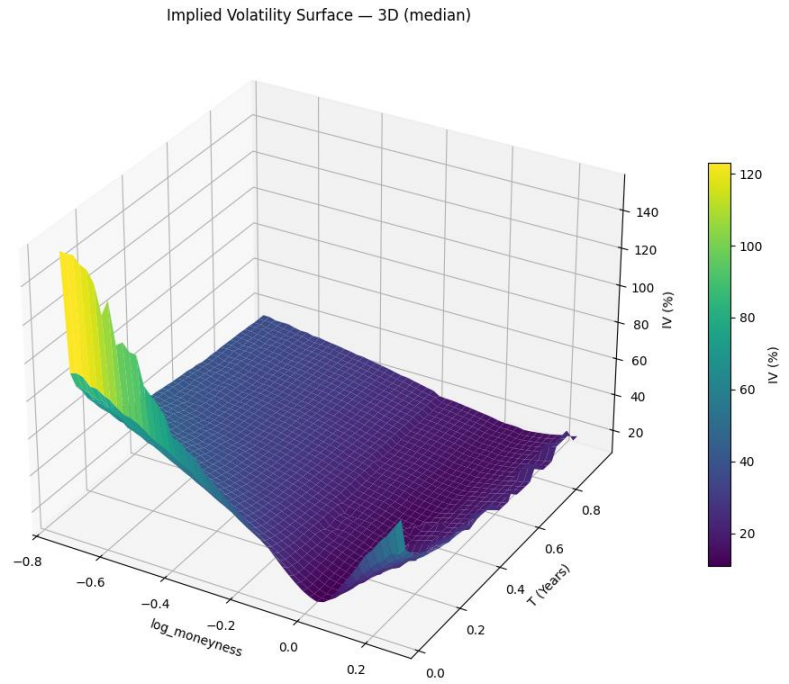
Resultados

O XGBoost atinge um R^2 de 87,5% e um RMSE de 0,0412, com viés praticamente nulo, revelando **elevada capacidade preditiva** apesar de ligeiramente menor que a evidenciada pelo modelo de *Random Forest*.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0436	0,0299	0,0222	1,461	1,348	87,79	0,0000
Teste	0,0412	0,0293	0,0199	1,404	1,474	87,51	-0,0158

A análise gráfica evidencia que **o modelo mantém a robustez e captura quase toda a estrutura não-linear da superfície**.

A distribuição dos pesos dos coeficientes das variáveis explicativas é mais equilibrado que o modelo RF, revelando **maior flexibilidade**.



Hybrid Random Forest

Formulação

$$\mathrm{IV}_i^{Hybrid_RF} = \mathrm{IV}_i^{Splines} + \hat{\varepsilon}_i^{RF}$$

Resíduos

$$\varepsilon_i^{Splines} = \mathrm{IV}_i - \mathrm{IV}_i^{Splines}$$

- Base modelo Splines capta estrutura global
- RF modela apenas resíduos (ajustes locais)
- Segue a metodologia do modelo ML, apenas com alteração do target ($\varepsilon_i^{Splines}$)

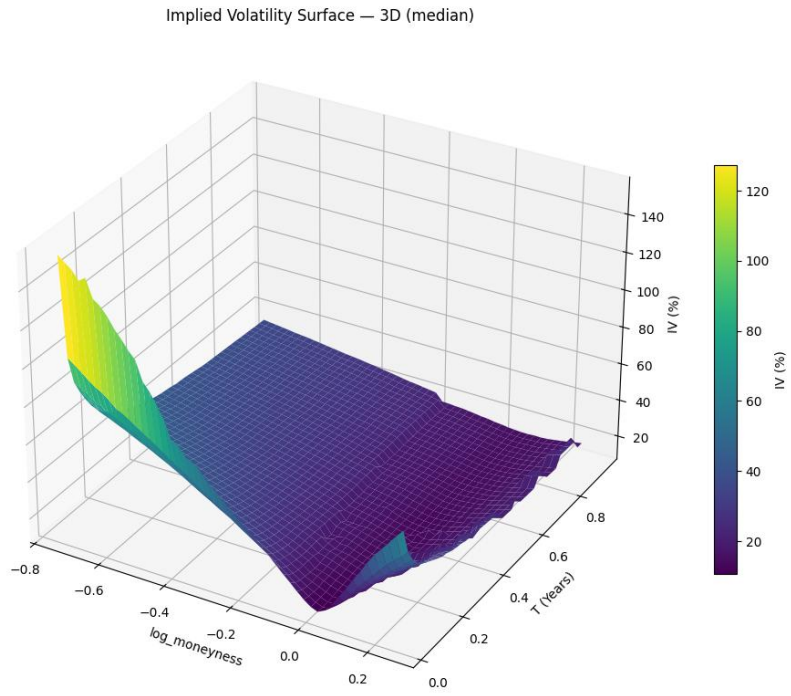
Resultados

O modelo híbrido *Random Forest* atinge um R^2 de 89,2% e um RMSE de 0,0383, cerca de 31% da volatilidade média, mostrando um **desempenho praticamente idêntico ao modelo de *Random Forest***.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0421	0,0288	0,0213	1,462	1,349	88,64	0,0000
Teste	0,0383	0,0275	0,0192	1,395	1,428	89,18	-0,0113

Graficamente, o desempenho do modelo é sólido, com **resíduos sem estrutura remanescente visível**.

Evidencia que a **abordagem híbrida não prejudica a previsão**, antes acrescenta suavidade e ligeira robustez ao capturar apenas as não-linearidades residuais.



Hybrid XGBoost

Formulação

$$\mathrm{IV}_i^{Hybrid_XGB} = \mathrm{IV}_i^{Splines} + \hat{\varepsilon}_i^{XGB}$$

Resíduos

$$\varepsilon_i^{Splines} = \mathrm{IV}_i - \mathrm{IV}_i^{Splines}$$

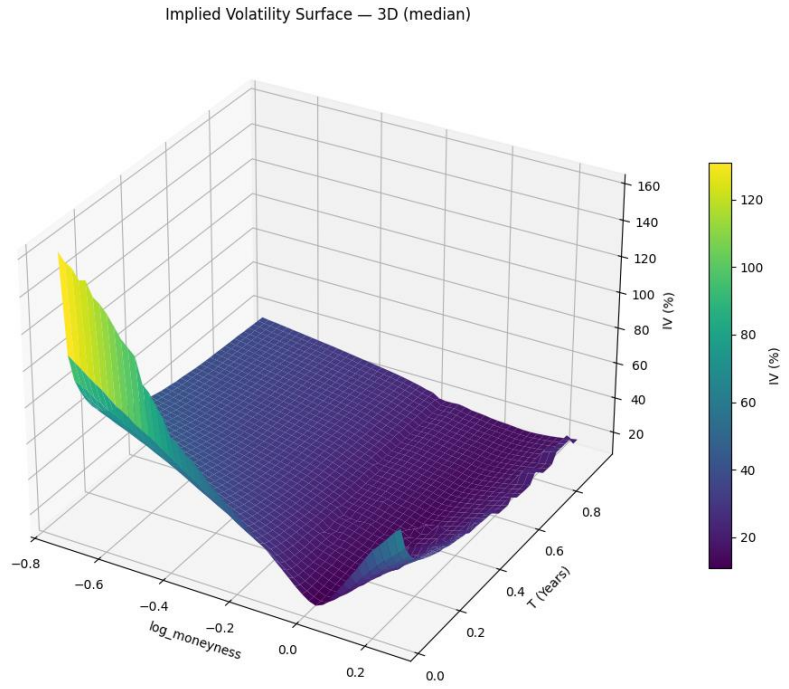
- Base modelo Splines capta estrutura global
- XGBoost modela apenas resíduos (ajustes locais)
- Segue a metodologia do modelo ML, apenas com alteração do target ($\varepsilon_i^{Splines}$)

Resultados

O híbrido XGBoost obtém um R^2 de 88,9% e um RMSE de 0,0388, também cerca de 31% da volatilidade média, evidenciando **elevada precisão e forte capacidade discriminativa**.

Amostra	RMSE	MAE	MedAE	RMSE/ MAE	RMSE/ MedAE	R^2(%)	BIAS
Treino	0,0426	0,0293	0,0220	1,454	1,335	88,34	0,0000
Teste	0,0388	0,0280	0,0199	1,385	1,409	88,92	-0,0110

O desempenho observado é muito próximo do obtido pelo modelo *XGBoost*. Evidencia que o modelo de *Splines* captura corretamente os padrões globais, e que o modelo *XGBoost* é eficaz ao nível das correções locais, **capturando com sucesso as não-linearidades residuais**.



Análise Comparativa

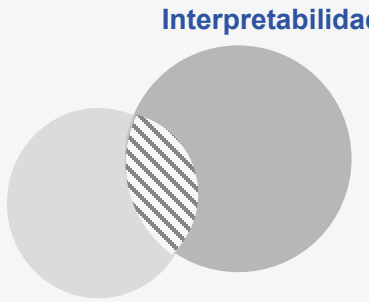
Modelo	R^2(%)	BIAS	RMSE	RMSE/σ	Relative Improvement (RI)
OLS	41,39	-0,0140	0,0892	72,03%	–
Polynomial	74,01	-0,0122	0,0594	47,96%	$RI_{(OLS;\ Poly)} = +33{,}41\%$
Cubic B-Splines	86,33	-0,0103	0,0431	34,81%	$RI_{(Poly;\ Splines)} = +27{,}44\%$
Random Forest	89,16	-0,0114	0,0384	31,03%	$RI_{(Splines;\ RF)} = +10{,}90\%$
XGBoost	87,51	-0,0158	0,0412	33,28%	$RI_{(Splines;\ XGBoost)} = +4{,}41\%$
Hybrid – RF	89,18	-0,0113	0,0383	30,93%	$RI_{(RF;\ H_RF)} = +0{,}26\%$
Hybrid - XGBoost	88,92	-0,0110	0,0388	31,34%	$RI_{(XGBoost;\ H_XGBoost)} = +5{,}83\%$

Comparação de Desempenho

Os modelos *Machine Learning* evidenciam um **desempenho significativamente superior** aos modelos clássicos.

Os modelos híbridos, por sua vez, registam apenas **ligeiras melhorias** de desempenho face aos modelos ML, mas conservando uma **base interpretável**.

Trade-off entre Flexibilidade e Interpretabilidade



Modelos híbridos representam o compromisso ideal entre ambos.

INTRODUÇÃO
4-8

TRATAMENTO DE DADOS
10-12

METODOLOGIA E RESULTADOS
14-22

CONCLUSÃO E RECOMENDAÇÕES
24-25

Principais Conclusões



Limitações dos modelos clássicos



Valor Conceptual dos Modelos Híbridos



Contributo dos Modelos de *Machine Learning*



Integração de Econometria e *Machine Learning*

Recomendações e Extensões Futuras

“The best way to predict the future is to create it.”



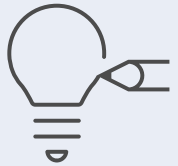
Dados

- Expansão da base de modelização
- Melhoria no cálculo da IV teórica



Metodologia

- Inclusão de variáveis exógenas
- Otimização avançada de hiperparâmetros
- Testes em períodos voláteis
- Modelização dinâmica da IVS ao longo do tempo



Caminhos Alternativos

- Híbridos baseados em modelos estruturais estocásticos
- Modelos ML avançados
- Aplicações práticas: *pricing*, *hedging*, *stress-testing*

Mestrado em Matemática Financeira

Study of Implied Volatility Surface with Machine Learning Techniques

Departamento de Finanças

Departamento de Matemática

Obrigado.